

Microsoft
Regional Director

TAIWAN CLOUD SUMMIT 2026

混合式 AI 架構

驅動企業敏捷與創新

不是「全雲端」或「全自建」的單選題，讓對的工作，在對的地方執行

Edward Kuo 郭家齊

Kingston Technology IT Senior Manager | Microsoft Regional Director | Microsoft MVP



ABOUT ME

關於我



Edward Kuo

管理者 · 開發人員 · 架構師
AI 應用策略者

Business • Cloud • AI



現職 | CURRENT

- **Kingston Technology IT Senior Manager**
- Microsoft Regional Director / Microsoft Most Valuable Professional



經歷 | EXPERIENCE

- 微軟技術研討會、.NET Conf 講師
- Taiwan Cloud Summit、DevOpsDays Taipei 講師
- 企業 DevOps 顧問與導入講師
- 大學院校 雲端 / AI / DevOps 客座講師

我們 AI 之路試點的過程


從基礎設施到智慧應用，逐步驗證價值，擴大影響力



持續優化 · 擴大應用 · 創造價值

透過試點學習與優化，逐步擴大 AI 應用範圍，驅動企業智慧轉型

導入 AI 的基礎設施挑戰



GPU & 記憶體難求

高階 GPU 和記憶體供給吃緊、價格高昂，採購與擴充週期長。



資料主權與法規

敏感資料外送公有雲，面臨個資法、合規與稽核壓力。



推論延遲

雲端往返延遲影響即時體驗，邊緣場景難以承受。



人才稀缺

AI 工程、MLOps 與維運工程人才難尋且成本高。



Token 成本失控

Agent 多輪推理與大量上下文，使用量與費用難以預估。



模型快速迭代

模型版本快速更替，自建環境難跟上升級節奏。

企業情境遠比個人環境的AI 開發複雜

導入 AI 不只是訓練模型，更要面對企業既有的多重環境與限制。



多環境並存

開發、測試、正式與災備環境並行，部署複雜度高。



多營運據點

跨國跨區的據點，網路延遲與資料落地規範各異。



多資料來源

ERP、CRM、MES、PLM 等系統資料分散且格式不一。



多資料敏感度

從公開到高機密，需分級保護與差異化處理。



多法規要求

金融、政府、醫療等不同產業的合規門檻並存。



多成本與效益

各場景投報率不同，需逐一權衡部署落點。

兩種迷思：全雲端 vs 全自建



迷思一：全部上雲

All-Cloud

優點

- 彈性高、可快速啟用
- 免自建機房與維運
- 隨需擴充、快速試錯

缺點

- 長期 OPEX 持續累積
- 敏感資料外流疑慮
- 跨網延遲影響即時應用



迷思二：全部自建

All-On-Prem

優點

- 資料完全自主掌控
- 成本可預測、低延遲
- 符合資料主權需求

缺點

- 高額 CAPEX 與折舊
- 人才與維運門檻高
- GPU 利用率常偏低

內部自建 AI Server 的六大障礙



基礎設施受限

運算力、機房的低延遲網路、儲存與電力供應均受硬體限制。



成本居高不下

CAPEX 與 OPEX 雙高，GPU 利用率卻常偏低。



沒有萬用方案

不同工作負載需求迥異，難以單一架構通吃。



人才稀缺

AI Server管理和維運與一般Server不同，量體大時，工程專才難尋且成本高昂。



複雜缺乏彈性

調整與擴展不易，架構難以快速響應市場，阻礙敏捷與創新。



治理不足

缺乏對模型、資料與安全的全面治理機制。

自建 AI Server 的真實成本

CAPEX | 資本支出

- **GPU 伺服器** 高階 GPU 與運算節點，單價高昂
- **機房建置** 機櫃、電力配置、結構強化
- **網路與儲存** 高速網路、共享儲存與備援

OPEX | 營運支出

- **電力與冷卻** GPU 高功耗，散熱與電費持續累積
- **維運人力** 系統、網路與 AI 維運團隊成本
- **折舊與升級** 硬體快速折舊，需定期汰換升級



關鍵提醒：僅約 7% 的工作負載能讓 GPU 利用率達 85% 以上，閒置運算力就是成本。先算清楚 TCO，再決定要不要全部自建。

公有雲 AI 方案：不只是租算力



公有雲的價值

- **即開即用**
免自建機房與維運，分鐘級啟用所需資源。
- **最新模型**
第一時間取得前沿模型，免自行追版升級。
- **彈性擴充**
尖峰與爆量隨需擴張，免為峰值超額採購。



完整平台能力

- **模型與代理服務**
模型目錄、Agent 服務與工作流程編排一站到位。
- **知識與工具整合**
知識檢索、工具與連接器串接既有系統。
- **可觀測與治理**
全線追蹤、日誌稽核與內容安全控管。

三種部署模式比較

比較構面	地端自建 On-Prem	公有雲 Public Cloud	託管 Hosting
成本模式	高 CAPEX	OPEX 隨用量	月租 / 混合
控制權	最高	較低	中等
效能延遲	最低延遲	受網路影響	中等
擴充彈性	受硬體限制	近乎無限	中高
資料主權	完全自主	依供應商	可指定區域
適合場景	敏感 / 即時	爆量 / 試錯	過渡 / 彈性

CAPEX = 資本支出 (一次性建置) OPEX = 營運支出 (持續性費用)

AI 部署不是二選一，而是一道光譜



混合式 AI 的本質：在這道光譜上，為每一種工作負載選擇最合適的落點。

混合式人工智慧架構：五大優勢

讓「混合式 AI 架構」真正驅動企業敏捷與創新的五個關鍵價值。

01



敏捷彈性

Agility

快速因應需求變化
，雲、地、邊緣彈
性選擇部署落點。

02



加速創新

Innovation

迅速導入新模型與
架構，安全試錯前
沿 AI 技術。

03



成本最佳化

Cost

雲端按需、地端承
載常態，免一次性
鉅額硬體投入。

04



效能與邊緣

Performance

推論落地機房與邊
緣節點，毫秒級低
延遲即時回應。

05



合規與資安

Security

敏感資料留在邊界
內，符合金融、醫
療與政府規範。

五大優勢，正是混合式 AI 驅動企業敏捷與創新的關鍵。

混合式 AI 如何驅動敏捷與創新



敏捷

Agility

- **雲地彈性部署**
依工作負載即時選擇雲端、地端或邊緣，不被單一環境綁死。
- **按需擴充因應變化**
尖峰交給雲端、免超額採購，快速回應業務與市場變化。
- **智慧路由與標準整合**
Agent 自動選雲或地，MCP 快速串接既有系統。




創新

Innovation

- **安全試錯前沿模型**
透過雲端模型開道安全存取前沿模型，支援高風險創新試驗。
- **快速導入新版本**
雲端評估新模型，地端只部署驗證過的版本，迭代不中斷。
- **開發者自助與代理落地**
自助工具鏈與多步驟代理功能，加速從概念到上線。

讓對的工作在對的地方執行，同時取得敏捷的速度與創新的空間。

核心理念：讓對的工作在對的地方



雲端負責：訓練與高負載

- 大規模模型訓練與微調
- 突發流量的彈性擴充
- 快速試錯與新模型評估
- 跨區協作與全球服務
- 大語言模型的應用與管理



地端負責：敏感與即時

- 敏感資料的本地推論
- 毫秒級即時回應需求
- 斷網仍須運作的場景
- 符合法規的資料邊界

兩者並非對立，而是同一套架構中互補的兩端。

優勢一：技術面



低延遲推論

即時工作負載在地端執行，毫秒級回應。



彈性擴充

尖峰流量交給雲端，免為峰值超額採購。



智慧路由

依任務自動選擇雲或地。



標準整合

透過 MCP 與連接器串接既有系統與工具。



快速迭代

雲端評估新模型，地端只部署驗證過的版本。



資源最佳化

高利用率工作留地端，避免 GPU 閒置浪費。

優勢二：人員與成本



人員面

- **降低維運門檻**
雲端代管平台分擔基礎設施維運壓力。
- **聚焦核心價值**
團隊專注應用與業務，而非機房與硬體。
- **人才更易延攬**
以標準雲服務為主，減少對稀缺專才的依賴。



成本面

- **CAPEX 轉 OPEX**
用多少付多少，避免一次性鉅額投資。
- **控管 Token 成本**
地端與雲端分別針對不同場景的模型進行調配
- **提高資源效率**
雲地分流讓昂貴 GPU 維持高利用率。

如何確保資安




資料不出邊界

敏感資料於地端推論，僅回傳結構化摘要至雲端。



身分與權限

整合企業身分識別，落實最小權限與存取控管。



安全連線

以 AI-tunnel / 私有連線傳輸，避免直接曝險。



金鑰管理

API Key 與憑證集中保管，杜絕硬編於程式碼。



合規與資料主權

資料留在指定區域，符合個資法與產業法規。



稽核與內容安全

全線路追蹤、日誌稽核與 Content Safety 過濾。

AI Agent：六大核心能力

能感知環境、自主規劃、選用工具、執行任務並從結果學習的 LLM 驅動軟體實體。



Reasoning 推理

進行多步邏輯思考與判斷。



Planning 規劃

將任務拆解為可執行步驟。



Tool Use 工具呼叫

呼叫 API、查資料庫、寫檔案。



Memory 記憶

維護短期與長期上下文。



Perception 感知

讀取資料、檔案與 API 回應。



Reflection 反思

自我評估並調整策略。

Agent 設計模式

Sequential

順序

任務依序交棒，前一步輸出為後一步輸入。

Parallel

並行

多個 Agent 同時處理，彙整後輸出。

Hierarchical

階層

Supervisor 統籌調度多個子 Agent。

Handoff

條件轉交

依情境動態轉交給合適的 Agent。

Group Chat

群組討論

多 Agent 對話協作，集思廣益。

Reflection

反思迭代

生成 → 批判 → 改進的自我修正循環。

AI Agent 為何消耗大量 Token？

架構差異：從線性對話 → 循環黑盒子，導致 Token 指數級增長

單獨使用 LLM (線性對話)



- 簡單問答，Token 線性消耗

VS.

AI Agent (循環黑盒子)



上下文不斷累積，指數級增長！



AI Agent Token 消耗激增的 5 大原因

1 上下文滾雪球效應




- 每輪迭代重新發送：
原始提示 + 歷史回應 +
工具結果 + 狀態
- 輸入上下文指數級增長

2 隱形程式碼掃描開銷



- 即使發送無意義訊息，
系統仍會掃描歷史程式碼與上下文
- 單次對話可能消耗
高達 **29,000** 輸入 Token

3 多代理協作的 「通訊稅」



- Agent 間頻繁交換資訊
- 輸入 Token 佔比
通常 > **53.9%**

4 隱藏的推理 (Reasoning) Token



- 模型內部產生大量鏈式思考
- 500 Token 的回答背後
可能消耗
20,000~50,000 個隱藏 Token

5 非確定性與無效探索



- 執行路徑隨機，Token 消耗
可能相差 30 倍
- 容易陷入重複修改或無效工具的
「死循環」

為什麼我們需要 Token 與 Agent 管理？

劇烈的成本差距



- 同樣花費 100 美元，
Agent 環境可能比
直接調用 API
貴 4.5 倍以上

避免大模型處理簡單任務 造成資源浪費



- Agent 專業化分工
- 簡單任務 → 地端模型
- 複雜任務 → 雲端模型

防止預算黑洞



- 缺乏管理機制時，
Agent 可能在背景進行
數百次無效循環
- 快速耗盡預算

Token 投入與成功率 不成正比



- 準確度在中間 Token 區間
達到峰值
- 過度投入只會因無效探索
而飽和甚至下降

提升可預測性與 ROI



- 優化 Token 投入產出比
- 確保系統穩定性
- 成本可預測
- 專業化效率最大化



總結：隨著開發模式從「單純用模型」轉向「AI Agent」，有效的 Token 與 Agent 管理，
是確保系統**穩定**、**成本可預測**與**專業效率**的必要工程手段。



Agent 的挑戰：記憶體與 Token 成本



為什麼 Agent 是「記憶體殺手」

- **LLM 本質無狀態**
每次推論都需重新組裝歷史對話與任務狀態。
- **多輪推理與工具呼叫**
單一任務常需 5–20 輪，序列長度快速膨脹。
- **多 Agent 與檢索注入**
KV Cache 倍數成長，RAG 再塞入大量文件片段。



Token 成本：企業最大挑戰

Agent 對企業最大的挑戰，是 Token 消耗過大、成本上升且難以控制。

混合式架構如何解

- 常態負載交由地端 SLM 處理，省下雲端 Token
- 雲端只接複雜推理與爆量，成本可預測
- 三層記憶體：GPU / DRAM / SSD 分層承載

混合式 AI 底層架構藍圖



Microsoft Foundry | 雲端控制平面

Models

Agent Service

Foundry IQ

Foundry Tools

Workflows

Observability



AI-tunnel / MCP | 僅回傳結構化摘要，敏感資料不外送



Foundry Local | 地端 / 邊緣執行平面

Windows PC

Linux

邊緣裝置

工廠 IPC


特殊終端

敏感資料

同一套控制平面，跨雲端到邊緣統一治理：離線可用、低延遲、無 Token 費用。


Microsoft Foundry + Foundry Local 混合式 AI 應用架構

使用 Foundry Local、Microsoft Foundry 與 Agent Framework，敏感資料留在地端，雲端負責高強度推理



Microsoft Foundry + Foundry Local 混合式 AI 應用架構

Agent Service 透過 GPT-4.1 推理；需個人化情境時，經 tunnel 安全呼叫本機 MCP 助手



Responsible AI：負責任的 AI

公平性

Fairness

可靠性與安全

Reliability & Safety

隱私與保密

Privacy & Security

包容性

Inclusiveness

透明

Transparency

問責

Accountability

Responsible AI | 平台落地能力



Content Safety

過濾、有害內容偵測



Evaluation

回應品質、安全性自動
評估



Tracing

OpenTelemetry 全線路
追蹤



Audit Logs

符合 ISO 42001、NIST
AI RMF

AI 不是越強越好，而是越能信任越好。

讓智慧落在最適位置



混合式 AI 可將智慧放在最適位置，既保護隱私，又能降低雲端運算成本，如：例行查詢、情境蒐集與個人歷程存取，都可由輕量本地模型處理，而非動用昂貴的大型模型。

混合式 AI 讓每一台裝置都成為智慧協作夥伴，也讓每個AI代理人成為能安全運用在地專業的專家。

雲地兼得，挑戰並存

//

過去我們常在雲端與地端之間二選一；在 AI 時代，不再是非此即彼，而是要同時擁有兩端優勢。

混合式架構雖為企業帶來效益，但也大幅提高開發複雜度，成為開發者的一大挑戰。

目前

我們 AI 戰略藍圖

以混合式 AI 式架構的企業 AI 拓譜

1 員工效率 AI

提升辦公效率
降低 OA 工作 Loading



- Word / Excel / PowerPoint 智慧生成
- Outlook 郵件摘要與建議
- Teams 會議摘要與行動整理
- 文件、簡報、知識快速整理

AI 協助員工完成日常工作
目標對象：全體員工

2 開發效率 AI

降低開發人員負擔
加速程式開發



- 程式碼生成與建議
- 測試、文件、重構
- API / 程式碼範例產生
- 提升開發品質與速度

AI 開發助理 / 程式碼諮詢
目標對象：開發人員 / IT 團隊

3 系統智慧化 AI

讓既有系統智慧化，
代理背景流程自動化



- AI Agent / Multi-Agent
- OCR / RAG / Workflow
- LLM 整合與權限管理
- 系統流程自動化與代理執行

AI / Agents 系統智慧化專家 / 流程助手
目標對象：系統開發團隊 / IT 部門

4 Open Source AI

技術研究與驗證平台，
最終回饋微軟生態系



- 研究各種 AI 方案
- 模型驗證與 PoC
- Local AI 評估與測試
- 新技術趨勢探索

AI 研究助理 / 技術探索助手
目標對象：AI 研究團隊



AI Agent 整合層

多樣化 Agent 與 AI，支援不同情境，
相互協作，提供智慧服務



員工
Agent



系統
Agent



流程
Agent



資料
Agent



知識
Agent



監控
Agent



底層 支援平台



Azure
雲端基礎設施



Microsoft Entra
身分與權限管理



Microsoft 365
協同與生產力



Data Security
資料安全與隱私

治理與安全



AI 治理
政策、規範與監控



合規與隱私
法規遵循與資料保護

AI 演進階段



AI Assistant
協助員工完成工作



AI Copilot
協助員工提升效率



AI Agent
代理流程，自動執行



AI Native Enterprise
AI 驅動企業營運與創新

策略價值



提高整體效率
降低重複性工作，提升生產力



加速創新
AI 輔助開發與創新，縮短專案時程



智慧化營運
代理背景流程，自動化與智能化



數據驅動決策
整合資料資產，驅動精準決策



安全與治理
確保合規與企業整合與治理



AI 能力平台
建立可擴展的企業 AI 能力

重視 Token 治理是新的議題

AI 編碼大規模落地，Token 成本正快速偏離產出曲線。

GARTNER 預測

2028

AI 程式碼開發成本恐超過開發者的平均年薪

成因：LLM Token 消耗激增 + 轉向用量計價。
資料來源：Gartner，2026 年 6 月

01 用量暴增

Copilot、Agent、RAG 全面導入，Token 消耗呈倍數成長；輕度使用者正快速變成主力使用者。

02 計價難預測

從席次授權轉向用量計價，廠商計費不透明，預算常比預期更早見底。

03 效益失衡

缺乏治理時，成本上升快過生產力增益，AI 的投資報酬被稀釋。


「Token 紀律無法只靠開發者自覺；沒有受治理的工程營運模式，成本會比效益更快失控。」
— Gartner

治理之道：把 Token 當雲端成本一樣治理

看得見、管得住、算得清

- 01 用量可觀測** 建立 Token 用量儀表板，依團隊 / 專案 / 模型即時歸因並設定告警。
- 02 用例分級授權** 依任務區分 Developer-led / With-agent / Agent-led，明確何時用 AI、用到什麼程度。
- 03 智慧模型路由** 簡單高頻任務交給小模型，前沿模型只保留給複雜的高價值工作。
- 04 情境工程降耗** 精簡 Prompt 與上下文、只給相關資訊，並用快取減少重複消耗。
- 05 制度化檢視** 設 Token 門檻與升級政策、自動監控，並於 sprint 回顧檢視高耗用流程。

趨勢與結論



■ 使用或計劃使用雲端部署 ■ 探索混合模式 ■ 堅持純本地端

實務上難以完全採雲端或完全採地端，混合式是回應真實需求



不是單選題

全雲端與全自建各有取捨，混合才是務實解。



讓對的工作落在對的地方

雲端管訓練與爆量，地端管敏感與即時。



資安與成本可兼顧

資料留在邊界內，CAPEX 轉 OPEX 控管成本。



一套架構統一治理

Microsoft Foundry 與 Foundry Local 雲地協作。

Microsoft
Regional Director

THANK YOU

謝謝聆聽

